TIPO: Práctica **CALIFICACIÓN:**

MATERIA: Extracción de conocimientos en Base de Datos **MAESTRO:** M.C. MARTHA CÁRDENAS MACIEL

ALUMNO: Mejia Gonzalez David **GRUPO:** 9 IDGS **FECHA DE APLICACIÓN:**

Practica 2. Pipeline ETL y Limpieza de Datos con Pandas

Instrucciones: Realizar un script de Python utilizando la librería Pandas, para realizar el ETL en el conjunto de datos del archivo pokemon.csv. Documente y evidencie el desarrollo de cada uno de los pasos indicados en cada Fase.

Modalidad: Individual

Objetivo de la Práctica: Desarrollar un flujo de trabajo ETL (Extract, Transform, Load) para extraer los datos crudos del archivo *pokemon.csv*, diagnosticar y corregir problemas de calidad de datos (desplazamientos de columnas, espacios en blanco, tipografía inconsistente y valores nulos/erróneos), e ingestar el conjunto transformado en un formato limpio listo para análisis.

El proceso de Extracción, transformación y carga (ETL) es un proceso de integración de datos que combina, limpia y organiza datos de uno o múltiples fuentes en un único conjunto de datos coherente. Luego carga esos datos en un *data warehouse*, *data lake* u otro sistema de destino.



Ilustración 1. Pipeline ETL Pokemon

Fase 1: Extracción (Extract)

En esta fase se realiza la lectura de la fuente primaria en un **DataFrame de Pandas** y la inspección inicial de metadatos.

1. Carga el *dataset* desde el archivo '*pokemon.csv*' utilizando Pandas.
2. Has una copia del *dataframe* y trabaja en ella para mantener los datos crudos (originales).
3. Verifica del conjunto de datos: estructura, registros totales, dimensiones y tipos de datos de cada columna.
    a. Inspecciona las primeras 5 filas o registros
    b. Obtén la estructura y tipos de datos del *dataframe*
    c. Obtén los datos estadísticos del dataFrame
    d. Cuenta los valores nulos por columna (utiliza **isnull().sum()**)

Fase 2: Transform (Transformación y Limpieza de Datos)

Al inspeccionar el *dataset* de se identifican las siguientes acciones de limpieza clave que deben ejecutarse, si identificas otras acciones de limpieza de datos documéntalas en este apartado.

Acciones de limpieza

1. Cambia el índice de la primera columna 'N.º'
2. Corrección de espacios en blanco.
    a. Algunos datos de las columnas *string* contienen espacios en blanco al inicio o al final (ej. ' Bicho', ' Normal', ' Veneno').
    Aplicar **str.strip()** en las columnas *string* para normalizar la representación de cadenas.
3. Reorganización de Registros Desplazados.
    Definir y documentar una estrategia para reasignar los valores correctos en las columnas correspondientes (N.º, Nombre, Tipo1, Tipo2, Altura, Peso, Legendario).
    a. Existen filas donde faltan valores o se concatenaron campos durante el guardado original, lo que provocó un desplazamiento horizontal de columnas.
    Ejemplo:
    Índice 14 (Beedrill): El campo **N.º** contiene '15 Beedrill', desplazando **Tipo1** a **Nombre** y enviando **Peso** a 0.0.
    Pokémon monotipo (Rattata, Raticate, Dratini, Dragonair, Mewtwo): Al omitirse el **Tipo2**, la **Altura** se guardó en la columna **Tipo2**, el **Peso** en **Altura**, y el peso real quedó en 0.0 o desplazó a la columna **Legendario**.
4. Estandarización de Categorías y Errores Tipográficos
    a. Existen valores en **Tipo1** y **Tipo2** con sinónimos, erratas o términos en inglés Ejemplo:
    'Wa ter', 'Hierba', 'Insecto', 'I ce', 'Veneno n', 'luchando', 'Lucha ng', 'psíquico', 'hada').
    Mapear y unificar la taxonomía oficial de tipos:
    cambiar 'Wa ter' a 'Agua', 'Hierba' a 'Planta', 'Insecto' a 'Bicho', 'I ce' a 'Hielo', etc. (Puedes utilizar el método replace())
5. Tratamiento de Valores Faltantes (NaNs)
    a. La columna Tipo2 contiene valores nulos legítimos (Pokémon de un solo tipo).
    Asignar la categoría 'Ninguno' estructurado para Tipo2 cuando aplique. (Puedes utilizar el método fillna())
    b. Legendario presenta nulos debido a los desplazamientos de filas.
    Colocar los valores de Legendario faltantes con 0 (Utiliza fillna(0)).
6. Corrección de errores Numéricos y Conversión de tipos de datos
    a. El campo **N.º** contiene el valor en cadena '14 4' para Articuno en lugar de 144.
    Corregir el ID numérico 144.
    Cambiar la columna **N.º** a numérico entero (utiliza astype(int))
    b. Legendario está almacenado como punto flotante (float64) con valores 0.0 y 1.0
    Cambiar la columna Legendario a tipo booleano (bool).

Fase 3: Load (Carga)

Exportación del conjunto de datos procesado y limpio a un archivo estructurado para su posterior análisis o modelado.

dataFrame_Limpio.to_csv('pokemon_limpio.csv', index=False)

Fase de Verificación del resultado

Revisar la integridad del *dataFrame* final procesado

Verifica del conjunto de datos: estructura, registros totales, dimensiones y tipos de datos de cada columna.

a. Obtén las primeras 10 filas o registros
b. Obtén las últimas 10 filas o registros
c. Obtén 10 registros aleatorios
d. Obtén la estructura y tipos de datos del *dataframe*
e. Obtén los datos estadísticos del *dataFrame*
f. Cuenta los valores nulos por columna (utiliza **isnull().sum()**)
g. Enlista los datos sin repetir de Tipo1 (Tipos de pokemones)

¿Qué cambios faltan por realizar en el set de datos resultante y como los aplicarías?

Conclusiones

Referencia de fuentes de información consultada