**TIPO:** Práctica **CALIFICACIÓN:**

**MATERIA:** Extracción de conocimientos en Base de Datos **MAESTRO:** M.C. MARTHA CÁRDENAS MACIEL

**ALUMNO:** **GRUPO:** 9 IDGS **FECHA DE APLICACIÓN:**

## Práctica 3: Análisis Exploratorio de datos

**Modalidad:** Individual

**Instrucciones: Realizar un script de Python utilizando la librería Pandas, para realizar el ETL en el conjunto de datos del archivo pokemon.csv. Documente y evidencie el desarrollo de cada uno de los pasos indicados en cada Fase.**

### Contexto del set de datos

El RMS Titanic era un transatlántico británico operado por la compañía *White Star Line*, considerado en su época como el objeto móvil construido por el hombre más grande y avanzado del mundo.

**El Viaje Inaugural:** Zarpó el 10 de abril de 1912 desde Southampton (Inglaterra) con destino a Nueva York, haciendo escalas previas en Cherbourg (Francia) y Queenstown (Irlanda).

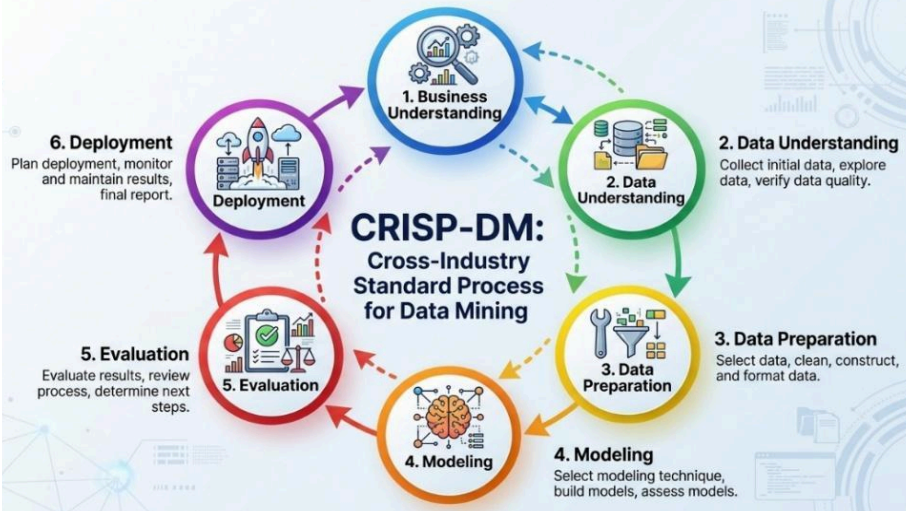
**El Impacto:** La noche del 14 de abril de 1912 a las 23:40, el buque colisionó lateralmente contra un iceberg en el Océano Atlántico Norte. El impacto rasgó el casco a lo largo de cinco de sus compartimentos estancos.

**El Hundimiento:** A las 02:20 del 15 de abril de 1912, el trasatlántico se partió en dos y se hundió por completo.

**La Causa de la Mortalidad Elevada:** A pesar de tener capacidad para más de 3,300 personas, el barco solo portaba **20 botes salvavidas** con capacidad total para 1,178 personas. Además, los botes fueron arriados inicialmente a mitad de su capacidad máxima debido a la falta de simulacros y la confusión del protocolo marítimo de evacuación.

### Objetivos Didácticos

El objetivo de la práctica es fortalecer la construcción de pipelines ETL (Extracción, Transformación y Carga) y desarrollar la ejecución de Análisis Exploratorios de Datos (EDA) guiados por la metodología estándar de la industria CRISP-DM (*Cross-Industry Standard Process for Data Mining*). En esta práctica se estarán revisando y poniendo en práctica los primeros 3 pasos de la metodología.




1. **Business Understanding (Entendimiento del Negocio):** Enfocado en definir los objetivos del proyecto, evaluar la situación actual del negocio.
2. **Data Understanding (Comprensión de los Datos):** Exploración de la estructura del conjunto de datos, dimensiones, auditoría de integridad (identificación de sesgos, registros duplicados, porcentaje de valores nulos, entre otros).
3. **Data Preparation (Preparación de los Datos):** Selección de atributos clave, limpieza de cadenas de texto, estandarización de tipos de datos e imputación de valores faltantes (mediante estadísticos de tendencia central como la media y la mediana).

**ETAPA 1: Extracción y Exploración Inicial (*Extract & Understanding*)**

El archivo de datos **titanic3.csv** consolida la lista oficial de pasajeros registrada para este viaje. Este conjunto de datos es uno de los *benchmarks* más utilizados en Ciencia de Datos para analizar cómo factores sociales, demográficos y económicos influyeron directamente en las probabilidades de supervivencia.

**Descripción de variables del dataset**

```
pclass – Passenger Class (1 = 1st; 2 = 2nd; 3 = 3rd)
survival – Survival (0 = No; 1 = Yes)
name – Name
sex – Sex
age – Age
sibsp – Number of Siblings/Spouses Aboard
parch – Number of Parents/Children Aboard
ticket – Ticket Number
fare – Passenger Fare
cabin – Cabin
embarked – Port of Embarkation (C = Cherbourg; Q = Queenstown; S = Southampton)
boat – Lifeboat
body – Body Identification Number
home.dest – Home/Destination
Pclass es un aproximado del estatus socioeconómico
```

Nos interesa responder a las siguientes preguntas con base en la exploración, limpieza, y análisis básico de los datos proporcionados. (Se contestarán al finalizar el desarrollo de la práctica)

1. ¿Cómo interactúan el género y la clase social en la probabilidad de supervivencia?
2. ¿Tener una familia pequeña o viajar solo afectó la tasa de supervivencia?
3. ¿Existe una diferencia significativa en la tarifa pagada (fare) entre quienes sobrevivieron y quienes no?

**ETAPA 2: Exploración Inicial de datos (Data Understanding)**

El objetivo de esta fase es inspeccionar la estructura inicial, tipos de datos y cuantificar la presencia de valores duplicados y nulos.

Paso 1: Explorar la Estructura, Dimensiones y Duplicados

1. Cargar el dataset desde archivo de datos.
2. Obtener la dimensión de los datos (filas, columnas).
3. Visualizar la estructura y tipos de datos de cada columna.
4. Verificar si hay valores duplicados en los datos. (dataframe.duplicated().sum())

Paso 2: Evaluación de Valores Nulos y Análisis de Columnas a Eliminar

5. Verificar cuantos los valores nulos hay por columna, ordenarlos de forma descendente. (dataframe.isnull().sum().sort_values())
6. Con base en el conteo obtenido en el paso 5, calcular el porcentaje de cada columna. Crear un dataframe con las columnas: **Cantidad de nulos** y **porcentaje**.

Las columnas candidatas a eliminar son aquellas que tienen exceso masivo de datos nulos o que no aportan al objetivo del análisis.

Con base en la exploración anterior completa lo siguiente:

a) Estadísticas clave del dataset

b) Selección de columnas a eliminar

Paso 3: Conteo y detalle de Valores Únicos por columna

7. Verificar y mostrar cuantos valores únicos hay por columna. (dataframe.nunique().sort_values(ascending=False)
8. Recorrer cada columna del dataframe e identificar las que tengan valores únicos menores que 10 (datafraeme[columna].nunique() <10) e imprimir los valores únicos de esas columnas.

Paso 4: Análisis exploratorio de datos

En esta etapa realizamos el análisis descriptivo y porcentual para responder preguntas específicas sobre los factores de supervivencia.

1. Obtenga el total de pasajeros.
2. Crear un dataframe con el conteo y porcentaje de sobrevivientes y no sobrevivientes (redondee el porcentaje a dos decimales con la función round())
3. Crear un dataframe con el conteo de pasajeros por la columna sexo y el porcentaje
4. Crear un dataframe con el conteo de sobrevivientes por la columna sexo y porcentaje de supervivencia.
5. Crear un dataframe con el conteo y porcentaje de pasajeros por clase.
6. Crear un dataframe con el conteo de hombres y mujeres por clase.
7. Calcule el porcentaje de supervivencia según parientes (sibsp)
8. Calcule el porcentaje de supervivencia según Hijos/Padres (parch)

Resultados clave obtenidos durante este paso:

Paso 5: Análisis mediante gráficas con Matplotlib

1. Generar un histograma general por edades de los pasajeros
2. Generar un histograma por edades de sobrevivientes y no sobrevivientes, puede ser por separado para hombres y mujeres.
3. Generar un histograma por clase, por edad de sobrevivientes y no sobrevivientes.

Comentar los hallazgos del Análisis Exploratorio de datos:

**Etapa 3. Data Preparation (Preparación de los Datos):**

En esta etapa se aplicarán algunas técnicas de imputación, eliminación de atributos redundantes, estandarización de tipos de datos e ingeniería de características.

1. Hacer una copia del dataframe.
2. Seleccionar solo las columnas relevantes requeridas ('pclass', 'survived', 'name', 'sex', 'age', 'sibsp', 'parch', 'fare', 'embarked')
3. Verificar la estructura del dataframe seleccionada
4. Cambiar el tipo de dato de la columna 'sex' a numérico (female -> 0, male -> 1)
5. Establecer una estrategia para llenar los valores NA de las columnas de age y fare (promedio, mediana o moda).
6. Verificar que los datos no tengan valores nulos

El dataframe procesado cargarlo y almacenarlo en un archivo nuevo csv: Exportar el conjunto de datos limpio a un nuevo archivo estandarizado listo para consumo analítico.

¿Qué cambios faltan por realizar en el set de datos resultante y como los aplicarías?

**Conclusiones**

**Referencia de fuentes de información consultada**